태양광 발전량 예측 개선을 통한 에너지 자립 실현

머신러닝을 활용하여

성함 블라인드 처리

발표 순서

01
연구 필요성 및 목표

02
연구 방법론

03
분석 결과

04
결론 및 한계

1 연구 필요성 및 목표

1 연구 주제

- 기상변수 외 대기 중 미세먼지 및 온실가스가 태양광 발전량에 미치는 영향을 분석하고, 이를 통한 최적 태양광 발전량 예측 모델 도출

2 연구 필요성

- 경상남도, 태양광 누적 설비용량 및 발전량 평균 5위
  간헐성이 큰 태양광 발전은 정확한 발전량 예측 매우 중요
- 글로벌 온실가스 배출량 지속적 증가
  기후변화는 대기 중 온실가스 농도에 영향을 받음
  이상 기후에 따른 태양광 발전량 변동
- OECD 평균 대비 한국의 높은 초미세먼지($PM_{2.5}$) 농도
  미세먼지는 태양광을 흡수 및 산란시켜 태양광 패널에 도달하는 빛의 양 감소
  (기존연구: 대기질 나쁨 조건에서 발전 감소율은 최대 22.6%)
  발전량 예측 성능 저하 가능성 존재
- 기상 데이터를 활용한 기존의 태양광 발전량 예측 연구는 많음.
  그에 반해, 미세먼지와 온실가스의 영향에 대한 관심은 제한적

3 연구목표

- LSTM, LightGBM, XGBoost, LightGBM-XGBoost 모델 중
  가장 우수한 태양광 발전량 예측 모델을 찾고 앙상블 모델의 예측력이
  기존 단일 모델에 비해 유의미한 향상을 보이는지 검증
- 기상변수와 함께 미세먼지 및 온실가스 농도 변수 반영 여부에
  따른 모델 예측 성능을 비교 분석

4 기대 효과

- 정확한 발전 계획 수립으로 에너지 자급자족형 인프라 구축에 기여
- 여름철 및 전력 수요 피크 시간대
  일정한 공급 예비율 유지 및 중앙 집중시스템과의 안정적인 연계 가능
- 향후 태양광 발전량 예측 모델 개발 및 적용 활용, 예측 정확도 향상 기여

연구 방법론 [1/4] | 연구 순서

1 Data collection

- Time
- Meteorological data
- Particulate matter
- GHG
- PV power generation

2 Feature selection [Elastic net]

Temperature and 8 other variables

3 Data preprocessing

4 Training data

Four scenarios

① Weather
② Weather + PM
③ Weather + GHG
④ Weather + PM+ GHG

5 K- Fold Cross Validation

Split 1	Train	Validate
Split 2	Train	Validate
Split 3	Validate	Train
⋮		
Split K	Validate	Train

6 Evaluation

[Model]
- Stacked ensemble
- LightGBM
- XGBoost
- LSTM

[Evaluation]
- RMSE
- MAE
- MSE
- R^2

7 Best model selection

1 선행 연구 조사 요약

- 다수의 연구에서 머신러닝/딥러닝 모델 성능 〉 기존의 시계열 모델 성능
  단, 머신러닝 모델 간 절대적 우위는 존재하지 않음

  ☐ 머신러닝 모델을 이용하여 태양광 발전량 예측

- 다수의 연구에서 RNN 모델의 예측력과 효율성이 좋은 것으로 나타남 (RNN: 시계열 데이터의 시간적 특징 파악에 사용)
  - RNN 기반 알고리즘 중 LSTM이 가장 성능이 우수하다고 알려져 있으며, 기존 연구에 많이 활용 되었음
    여러 파생모델이 있지만, 입력 변수의 예측력 평가를 위해

  ☐ 기본 LSTM 모델 사용
  ☐ LSTM과 유사한 성능을 보이는 XGBoost, LightGBM 모델 사용

- RNN-CNN 하이브리드 모델에 관한 연구 (CNN: 시계열 데이터의 공간적 특징 파악에 사용)
  단, 본 연구는 **한국 경남 지역**의 시간당 평균 태양광 발전량을 예측 (지리적, 공간적 요소 고정)

  ☐ CNN 모델 고려 하지 않음

- 앙상블 및 하이브리드 모델이 단일 모델 대비 예측력이 우수
  단일 모델과 앙상블 모델의 성능 비교를 위해 LightGBM – XGBoost 기반의

  ☐ Stacked ensemble 모델 사용

[최종 사용 모델]

- Stacked ensemble (LightGBM – XGBoost)
- LightGBM
- XGBoost
- LSTM

[평가 지표]

RMSE / MAE / MSE / R^2

1 XGBoost

- Gradient Boosting Decision Tree(GBDT)기반의 개선된 모델
- 특장점
  - 수준별(level-wise) 트리 성장
  - 병렬 처리를 통한 학습 속도 향상
  - 과적합 방지를 위한 정규화 (L1, L2)
  - 다양한 데이터 분석 경진대회에서 우수한 성능 입증

3 LightGBM

- GBDT기반 XGBoost 단점 보완 모델 (계산 속도 및 효율적 메모리 사용) 높은 유연성을 기반으로 복잡한 데이터 패턴 학습 및 우수한 예측력
- 특장점
  - 깊이 제약이 있는 리프별(leaf-wise) 트리 성장
  - 빠른 계산 속도와 효율적 메모리 사용(대용량 데이터 처리)
  - 과적합 방지를 위한 다양한 정규화 기법(L1, L2, GOSS, EFB)

3 LSTM

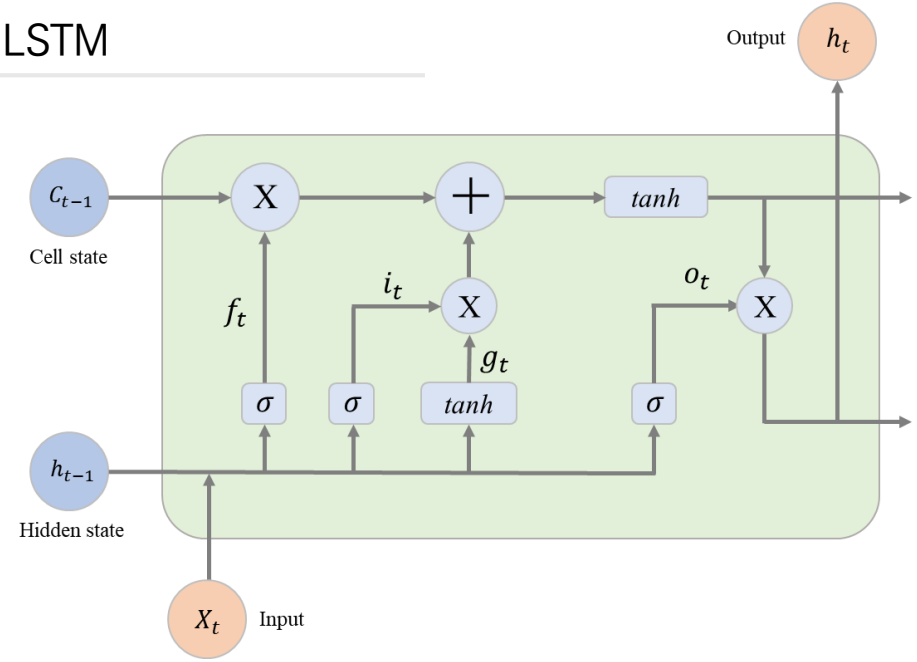

4 Stacked ensemble

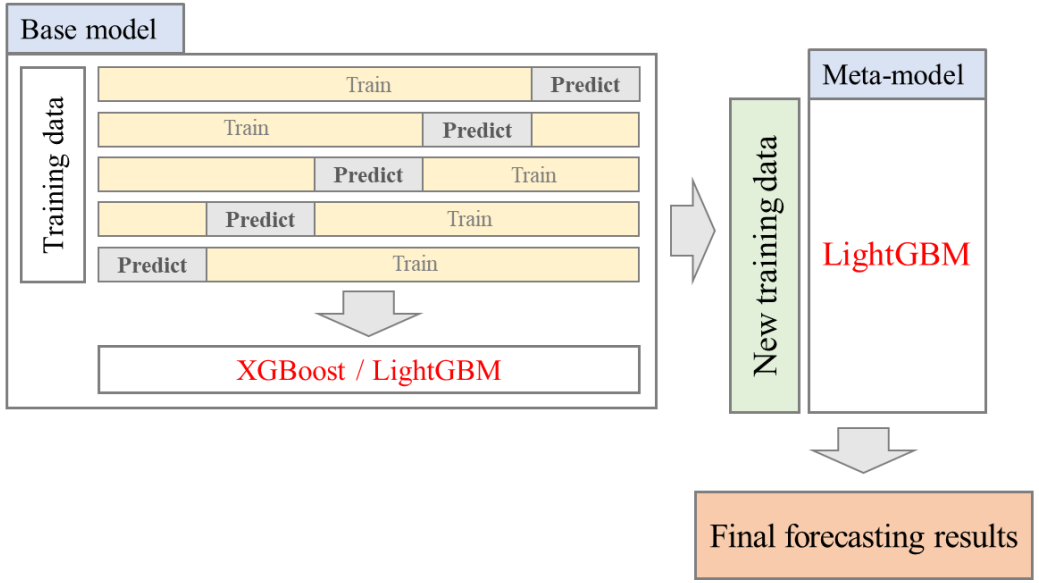

1 데이터 수집 및 전처리

- 수집 기간: 2020년 01월 01일 00시부터 2023년 08월 31일 23시까지
- 대상 지역: 대한민국 경남
- 데이터 종류
  - 기상 데이터: 온도, 풍속, 풍향 등 총 11개
  - 미세먼지 및 온실가스 농도 데이터: PM_{10},$PM_{2.5}$,SO_2, NO_2, O_3, CO
  - 태양광 발전량 데이터: 시간당 태양광 발전량(Mwh)
- 데이터 전처리
  - 기상 및 미세먼지, 온실가스 데이터는 경남 지역 전체 시간당 평균값으로 재취합 (해상도: 1h)
  - 기상 변수 간 높은 상관관계 및 다중공선성 문제 발생
    - ☐ Elastic net 을 이용해 차원축소 진행: 최종 9개 변수 선정(강수량, 이슬점 변수 제외)

2 최종 사용 데이터

- 학습 기간: 2020년 01월 01일 00시부터 2023년 07월 31일 23시까지
  예측 기간: 2023년 08월 01일 00시부터 31일 23시까지

구분	변수 특징	데이터(해상도: 1h)
입력	시간	년, 월, 일, 시
	기상 변수	온도, 풍속, 풍향, 습도, 기압, 일사량, 일조량, 전운량, 지면온도
	미세먼지	PM_{10}, $PM_{2.5}$
	온실가스	SO_2, NO_2, O_3, CO
출력	태양광 발전량 데이터	

[기상변수 간 상관관계 히트맵]

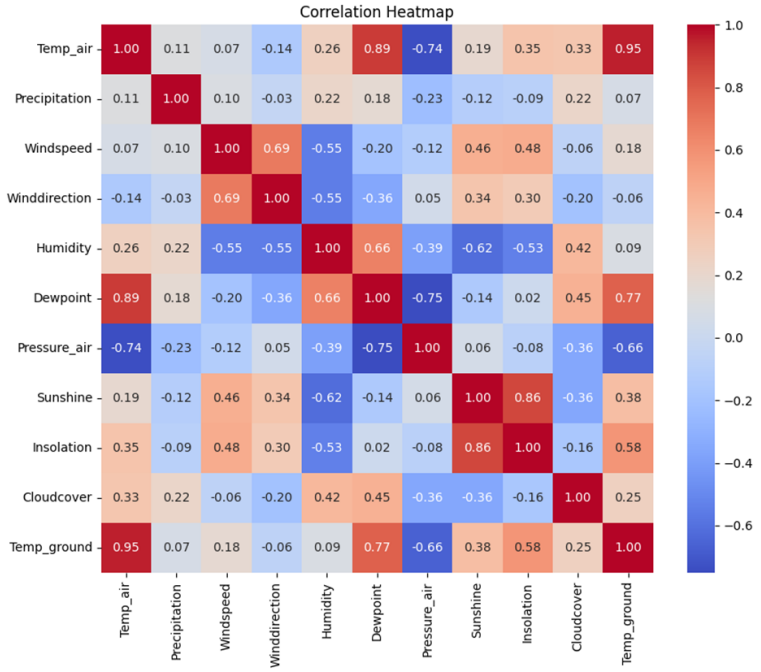

[데이터셋 조합]

구분	데이터 셋
1	기상변수
2	기상변수 + 미세먼지
3	기상변수 + 온실가스
4	기상변수 + 미세먼지 + 온실가스

1 모델 비교

- Single 모델
  - LightGBM: 변수에 관계없이 가장 우수한 성능
  - XGBoost: LightGBM과 유사한 성능 (Δ AVG_RMSE = 1.08)
  - LSTM: 가장 낮은 성능 (R^2 〉 0.95)
- Stacked ensemble: Single 모델 대비 예측력 향상
  (RMSE, 최대 15.52% 향상)
  복합 환경 변수를 포함한 다변량 데이터에서 강력한 예측 성능

2 변수 비교

- **미세먼지** 농도 반영 시
  - 성능 향상 모델: Stacked ensemble, LightGBM
  - 성능 저하 모델: XGBoost, LSTM
- **온실가스** 농도 반영시
  - 성능 향상 모델: Stacked ensemble, LSTM
  - 성능 저하 모델: LightGBM, XGBoost
- 미세먼지 및 온실가스 반영에 따른 모델 예측 성능 향상 여부는 모델에 따라 다름. 또한 기상 변수 대비 성능 향상 정도도 크지 않음
  (최대 ΔRMSE = 0.52%)

  □ 이는 미세먼지와 온실가스가 태양광 발전량 예측 시 주요 변수로 작용하지 않음을 시사

[모델 성능 평가 결과]

Dataset		Model	RMSE	MAE	MSE	R^2
1	Weather	Stacked ensemble	11.0401	6.6573	121.88	0.9854
		LightGBM	11.5406	6.8913	133.1844	0.9840
		XGBoost	11.7203	7.1504	137.3665	0.9835
		LSTM	17.3475	12.4682	300.9371	0.9639
2	Weather + PM	Stacked ensemble	10.9826	6.5692	120.6165	0.9855
		LightGBM	11.4977	6.9889	132.1973	0.9841
		XGBoost	13.0001	7.7861	169.0039	0.9797
		LSTM	18.6931	13.5628	349.4316	0.9581
3	Weather + GHG	Stacked ensemble	11.0030	6.6166	121.0668	0.9855
		LightGBM	11.7156	7.0447	137.2564	0.9835
		XGBoost	12.6112	7.5726	159.0428	0.9809
		LSTM	16.8774	12.1153	284.8481	0.9658
4	Weather + PM/GHG	Stacked ensemble	10.7245	6.4501	115.0156	0.9862
		LightGBM	11.2146	6.9358	125.7684	0.9849
		XGBoost	12.8100	7.5284	164.0954	0.9803
		LSTM	19.6150	14.8621	384.7480	0.9538

1 Stacked ensemble 모델 간 비교 분석

- **'기상 + PM'**

  Base 모델에서 XGBoost 비율은 24.07%로, 'Weather' 대비 7.8% 증가

  'Weather' 대비 모델 성능 개선 (RMSE 0.52%, MAE 1.32%)

  – 미세먼지 변수는 XGBoost 모델에 더 적합한 변수로 작용

- **'기상 + PM/GHG'**: 가장 우수한 모델 / 'Weather' 대비 모델 성능 개선 (RMSE 2.85%, MAE 3.11%)

  LightGBM의 비율은 88.40%로 4가지 스택 앙상블 모델 중 가장 높음

  – LightGBM이 다변량 데이터의 복잡한 상호작용 및 비선형 패턴을 정확하게 포착 및 예측

  – XGBoost는 LightGBM에서 발생할 수 있는 과적합 방지 및 모델 일반화 능력 향상에 기여

[변수별 최적 모델의 세부 구조]

Dataset	Base model			RMSE	MAE
	LightGBM	XGBoost	Total		
Weather	5 (83.81%)	4 (16.19%)	9	11.0401	6.6573
Weather + PM	5 (75.93%)	6 (24.07%)	11	10.9826	6.5692
Weather + GHG	6 (86.90%)	5 (13.10%)	11	11.0030	6.6166
Weather + PM/GHG	5 (88.40%)	2 (11.60%)	7	10.7245	6.4501

[스택 앙상블 모델의 태양광 발전량 예측 그래프 (Weather + PM/GHG)]

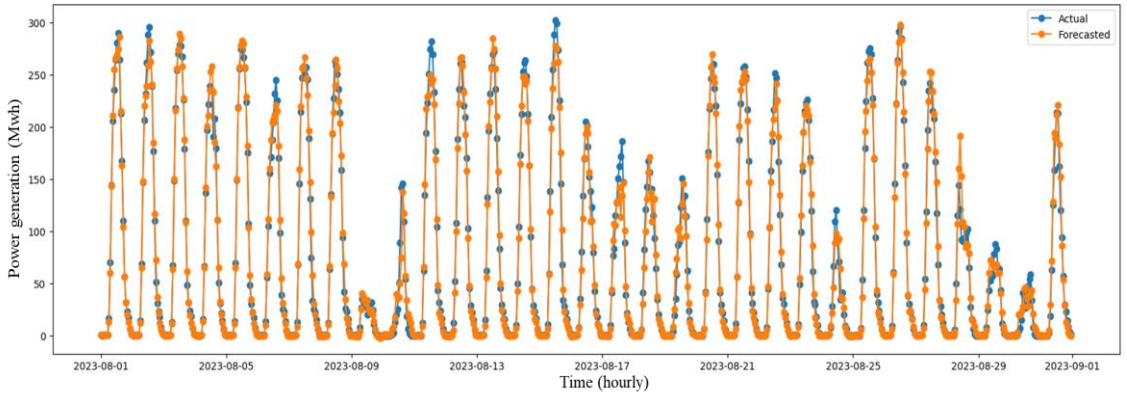

1 선제적인 기상이변 예측의 중요성

- 8월 13일, 11.7일의 연속적, 기록적 폭염 발생(*기상청)
  - 한국의 여름철은 태풍과 폭염이 연달아 발생, 전력 수요 변화가 매우 큼
- 폭염으로 인한 정전의 예시: 2020 캘리포니아 대정전
  - 폭염으로 인한 전력 수요 급증에 대한 예측 실패
  - 급진적 에너지 전환 정책으로 인한 예비 전력 부족

□ 피크 시간대 및 전력 수요 급증 시 안정적인 전력 공급을 위해 발전량 예측 정확도 개선에 앞서 선제적인 기상이변 예측 매우 중요

2 태양광 발전 증가로 인한 과전압 문제

- 여름철 최대 전력 소비 시간의 변화: 16~17시 <- 기존 14~15시
  미계량 태양광 설비가 중앙 전력 수요 감축과 지역 전력 공급에 기여
  총 태양광 발전 용량 약 20.3GW, 그 중 75% 실시간계량X (21.07. 기준)
- 국내 태양광 발전량 1위 전남지역: 전력계통과 연계 미흡
  지역 내 발전량 증가 및 중앙 전력 시스템 부하 감소: 과전압
  - 설비 고장, 에너지 손실 발생

□ 폭염 시 일사량 증가에 비례하여 발전 믹스를 조정

□ 태양광의 지역 발전 비중 확대를 고려한 수요 예측 필수

[경남 일평균 태양광 발전량 및 최고 기온 추이 (23.08.)]

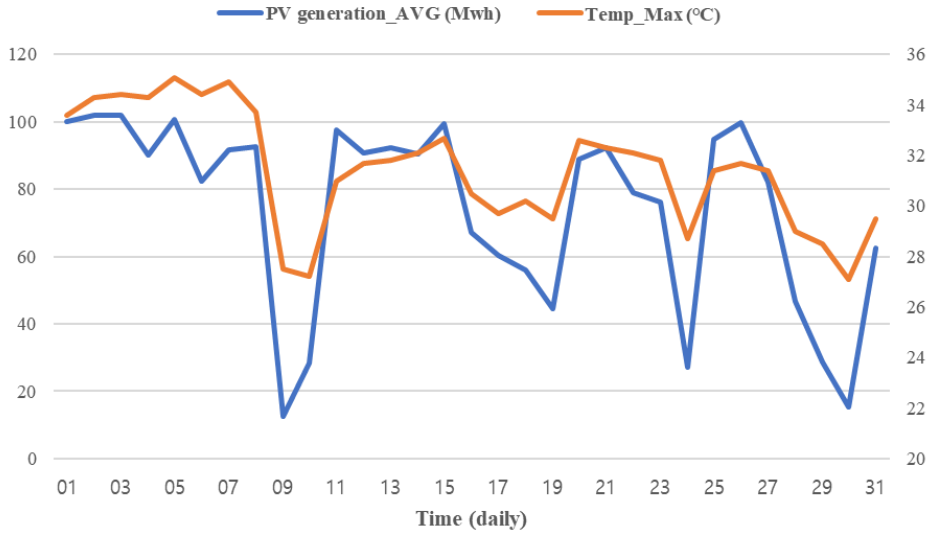

[시간대별 실제 전력 수요 및 시장 수요]

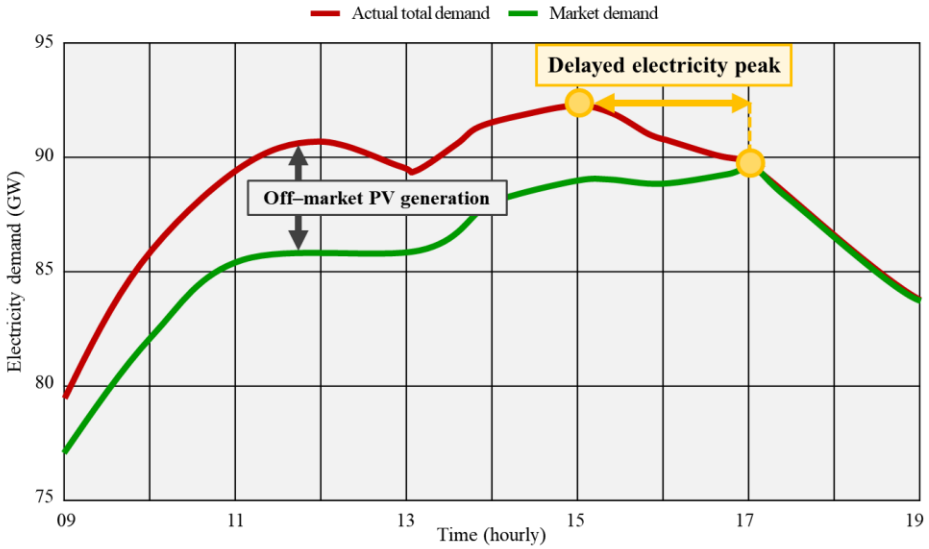

4 결론 및 한계

1 결론 및 시사점

- 기상변수 및 미세먼지, 온실가스 변수를 반영한 머신러닝 기반 태양광 발전량 예측

- 태양광 발전량 예측을 위한 4가지 머신러닝 모델 비교 평가
  - 단일 모델 : LightGBM
  - □ Light GBM-XGBoost Stacked ensemble 모델이 가장 우수 (RMSE 기준, 최대 15.52% 향상)

- 기상 변수의 조합 검토
  - 발전량 예측 성능 저하 요인: 강수량, 이슬점

- 기상 변수만 반영한 태양광 발전 모델 사용
  - 환경 변수 고려 시 모델 성능 향상 존재
  - □ 기상 변수 대비 큰 성능 향상X, 오히려 모델의 복잡도 증가

2 한계

- 계절별 기온 차가 큰 한국 기준 연구
  - 여름/겨울 철에 따라 태양광 발전량이 크게 달라짐
    이에 예측력에 영향을 미치는 주요 변수가 동적으로 변화
  - □ 겨울철 예측 결과는 본 연구와 다를 수 있음
  - □ 기후변화에 적응할 수 있는 모델 개발 필요 (일기예보 고려)

- 미세먼지 및 온실가스 변수의 상관관계 고려하지 않음
  해당 변수의 상관관계 관련 선행 연구 존재
  - PM_{10}과 $PM_{2.5}$ 사이의 높은 상관관계
  - $PM_{2.5}$와 O_3 사이의 유의미한 상관관계
  - □ 최적의 태양광 발전량 예측 모델을 구축하기 위해 추가적인 변수 선택 과정이 필요

감사합니다