2024 경상남도 빅데이터 분석 공모전
분석 보고서

[공모명: 태양광 발전량 예측 개선을 통한 에너지 자립 실현]

Ⅰ. 연구 배경 및 필요성

글로벌 탄소 중립을 달성하려면 깨끗하고 재생 가능한 에너지 전환이 필요하다. 많은 국가들이 온실가스 배출량을 줄이고 전력 계통에서 재생에너지의 비중을 늘리기 위해 노력하고 있다. 특히 한국 정부는 2050년까지 Net-zero를 달성하기 위해 2021년 10월 '2050 탄소 중립 전략'을 발표했다. 이 전략에는 전력 수요 관리 개선, 석탄 화력발전 영구 폐쇄, 재생에너지 발전 비중을 70.7%까지 확대하는 등의 내용이 포함되어 있다. 한국 정부는 태양광 중심의 재생에너지 발전 정책을 시행해 왔으며, 태양광 발전 비중은 다른 OECD 국가보다 높은 수준이다. 이러한 정부 정책에 발맞춰 경상남도는 지속적으로 태양광 등 재생에너지 설비를 확충하고 있으며, 국내 지역별 태양광 누적 설비용량 및 누적 발전량에서 평균 5위를 차지하며 상위권을 유지하고 있다. 특히 2019년 2월, 경남 창원 국가산업단지는 가장 먼저 스마트 그린 산단으로 지정되어 에너지 자급자족형 인프라 구축사업을 추진하고 있다. 이 사업은 재생에너지 기반 자립형 인프라를 통해 산단의 에너지를 충당하고 기존 에너지원을 대체하여 온실가스를 저감할 수 있다. 에너지 자립형 인프라 구축은 단순한 에너지 전환을 넘어 전력 공급의 탄력성과 신뢰성을 높이는 데 중요한 역할을 한다. 스마트 그린 산단 외에도 3MW의 소규모 태양광설비 설치계획을 담은 '도 소유·관리 공공청사 태양광설비 단계별 보급 계획'등의 다양한 태양광 정책 들을 발표하고 있다. 이처럼 경상남도는 태양광 중심의 마이크로 그리드를 구축하여 자급자족형 전력망을 계획 및 운영하고 있다. 따라서 대규모 산업 단지의 전력 수요를 충족하기 위해서는 태양광 발전을 포함한 신재생 에너지 발전 설비의 확대가 불가피하며, 마이크로 그리드는 태양광, 풍력, ESS 등 다양한 재생 가능 에너지원과 결합하여 독립적으로 운영될 수 있는 시스템이다. 하지만 다수의 소규모 분산형 전원은 안정적인 발전 및 통합 관리의 어려움이 있다. 완전하고 안정적인 에너지 자립을 위해서는 정확한 발전량 예측을

통해 중앙 전력망과의 통합 시 조율을 원활하게 할 수 있다. 발전량 예측 정확도의 제고는 전력 공급의 안정성을 높이고, 부하 예측 및 관리를 통해 중앙 발전소의 역할을 보완하는 데 기여한다. 또한 정확한 예측을 기반으로 한 통합 관리 시스템을 구축하면 에너지 자립이 가능해지며 및 전력 공급 중단에 덜 취약한 시스템을 갖추게 된다. 결과적으로, 태양광은 국내 차세대 에너지 정책에서 필수적인 역할을 담당하고 있으며, 본질적으로 간헐성이 큰 태양광의 안정적인 에너지 수급을 위해서는 정확한 태양광 발전량 예측이 중요하다.

일반적으로 태양광 발전은 기상 조건에 민감하게 반응한다. 하지만 그 외의 환경적 요인으로 대기중 초미세먼지는 태양광이 패널에 도달하기 전, 빛을 흡수 및 산란시켜 태양광 복사량과 발전량을 감소시킬 수 있다. 한국의 $PM_{2.5}$ 농도는 2019년 이후 지속적으로 감소하고 있지만, 주요 OECD 국가에 비해 여전히 높은 수준이다. 또한 태양광 발전 효율은 미세먼지 농도 증가에 따라 감소하며, 대기질 '나쁨' 조건에서 태양광 발전 감소율은 최대 22.6%에 달한다.

다른 환경적 요인인 온실가스(NO_2, SO_2 등)는 대기 중 농도가 매우 낮아 발전량에 미치는 영향이 미미하다는 기존 연구와 달리, 국제에너지기구(IEA)에 따르면 2022년까지 전 세계 1인당 온실가스 배출량은 지속적으로 증가하고 있다. 기후 변화는 대기 중 온실가스 농도에 영향을 받기 때문에, 이상 기후에 따른 태양광 발전 효율 변화가 발생할 수 있다. 따라서 본 연구에서는 태양광 발전량 예측 모델에 기상변수와 함께 미세먼지(PM_{10}, $PM_{2.5}$) 및 온실가스(SO_2, NO_2, O_3, CO) 농도 데이터를 고려하여 이들이 모델의 예측력에 미치는 영향을 분석한다. 본 연구 결과를 토대로 태양광 발전량 예측 정확도를 개선하여 재생에너지의 불확실성을 완화할 수 있으며, 전력망의 안정적이고 효율적인 운영에도 어느 정도 기여할 수 있을 것으로 기대된다.

II. 선행 연구 조사

- 대다수 머신러닝 알고리즘은 기존의 시계열 모델을 능가하는 성능을 보인다.
  그러나 머신러닝 모델 간의 확정적 우위는 존재하지 않는다.
- 최근 연구에서는 다양한 조건에서 기존 인공신경망보다 RNN 네트워크의 효과성이 더 우수하다는 것을 보여준다. 또한 RNN과 CNN 기반 모델이 널리 사용되고 있으며,
  전자는 발전 데이터의 시간적 특성을 파악하는 데 사용되고
  후자는 공간적 특성을 파악하는 데 사용된다.
- 일반적으로 앙상블 및 하이브리드 모델이 단일 모델보다 예측력이 더 우수하다.
- 태양광 발전량 예측 연구는 기상 데이터에 초점을 맞추는 경우가 많으며,
  미세먼지와 온실가스의 영향에 대한 관심은 제한적이다.

해당 연구는 머신러닝 모델을 활용하여 태양광 발전량을 예측한다. 기존 연구에서 다양한 모델들이 활발히 제안되고 있지만, 본 연구에서는 기존 연구에서 주로 활용되는 모델을 사용하여 입력 변수의 예측력을 비교하고자 한다. LSTM은 RNN 기반 알고리즘 중 가장 성능이 우수한 알고리즘으로 꼽히며 수많은 파생모델이 만들어졌지만, 본 연구에서는 변수의 예측력 평가를 위해 표준 LSTM 모델을 사용한다. 예측에서 LSTM과 유사한 성능을 보이는 LightGBM과 XGBoost 모델 또한 사용한다. 또한 스태킹 앙상블 모델인 LightGBM-XGBoost를 기반으로 한 모델을 사용하여, 단일 모델과 앙상블 모델의 성능 차이를 비교한다. 그러나 시계열의 공간적 특성을 포착하는 CNN 모델은 고려하지 않는다. 이는, 해당 연구가 대한민국 경남 지역의 시간당 평균 태양광 발전량을 예측하기 때문에 지리적, 공간적 용인이 고정되어 있기 때문이다.

본 연구의 목적은 다음의 두 가지이다. (1) LSTM, LightGBM, XGBoost, LightGBM-XGBoost 모델 중 가장 우수한 태양광 발전량 예측 모델을 찾고 앙상블 모델의 예측력이 단일 모델보다 유의미한 향상을 보이는지 검증한다. (2) 기상요인 외에 미세먼지 및 온실가스 변수 반영 여부에 따른 모델 예측 성능을 비교 분석 한다. 이 연구의 나머지 부분은 다음과 같이 구성된다: 2장에서는 사용된 모델과 지표를 소개한다. 3장에서는 사용된 데이

터와 모델의 예측 결과를 설명한다. 마지막으로 4장에서는 연구의 결론과 한계점을 제시한다.

Ⅲ. 연구 방법론

본 연구에서는 단일 머신러닝 모델로 Light GBM, XGBoost, LSTM을 사용하며, Light GBM-XGBoost 기반의 스택 앙상블 모델도 고려한다. 아래에서는 이 연구에서 사용된 모델과 모델 및 변수의 예측력을 평가하기 위한 평가 지표에 대해 간략하게 설명한다. 그림 1은 연구 순서를 나타낸다.

[그림1. 연구 순서도]

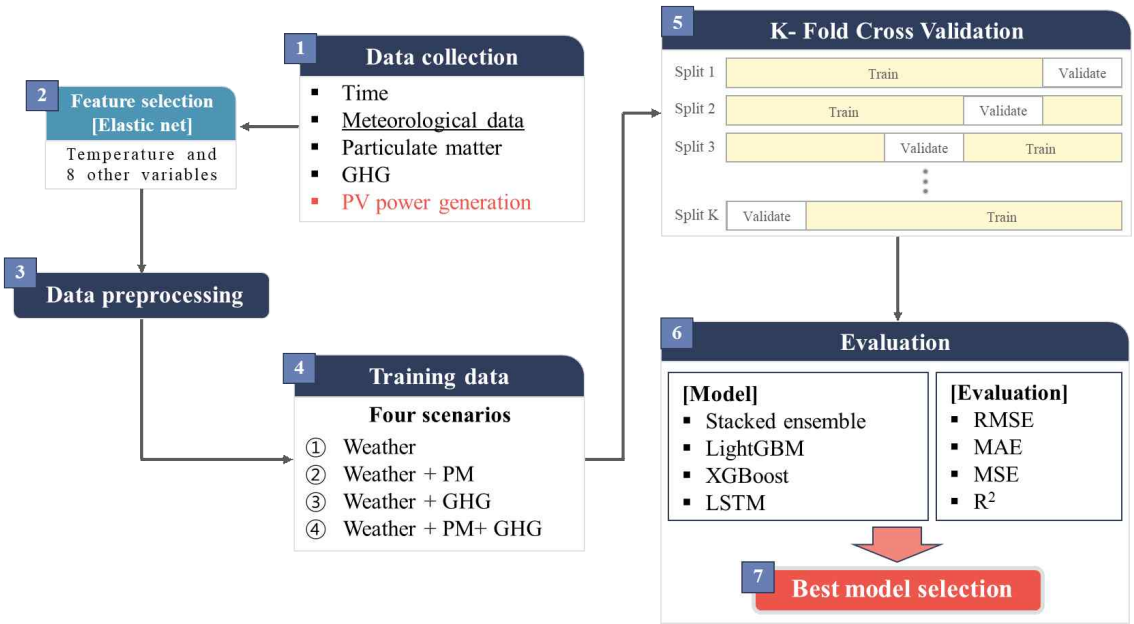

3.1 XGBoost

XGBoost는 gradient boosting decision tree (GBDT)를 기반으로 하는 알고리즘이다. XGBoost는 여러 개의 약한 트리 모델, 주로 분류 회귀 트리를 반복적으로 생성하고 결합하여 강력한 회귀 모델을 구축한다. 이 모델은 먼저 일정 수의 약한 학습자를 구축하여 이전 반복에서 얻은 잔여 오차에 대해 학습하고, 마지막으로 각 의사 결정 트리의 예측 결과를 합

산하여 최종 회귀 모델을 생성한다. XGBoost는 L1 및 L2 정규화를 사용하며, 손실 함수에 대해 2차 테일러 확장을 적용한다. 또한 계산을 최소화하고 과적합을 피하기 위해 컬럼 샘플링이 지원되며, 수평적 의사 결정 트리 성장 전략을 사용한다. XGBoost는 리프 노드 간에 학습 속도를 분산하고 각 트리의 가중치를 낮추며 각 반복이 끝날 때 추가 학습을 위한 가용 공간을 갱신한다.

3.2 Light GBM

Light GBM은 Microsoft Research에서 제안한 의사 결정 트리 기법을 기반으로 구축된 분산 GBDT이다. Light GBM 회귀, 분류 및 기타 머신 러닝 문제를 해결하는 강력한 접근 방식이며, LightGBM은 기존 GBDT 방식보다 10배 빠른 계산 속도와 1/3의 메모리만 필요로 하며, 예측력이 뛰어나다. 또한 L1, L2 외에 exclusive features bundling (EFB)와, gradient-based one-side sampling (GOSS)이라는 두가지 정규화 조건이 해당 모델에 포함되어 있어 과적합 문제를 방지하고 대용량 데이터에 적합하다. Light GBM 모델은 XGBoost와 달리 깊이 제한이 있는 리프 지향 트리 성장 전략을 사용한다. 히스토그램 알고리즘은 연속 데이터를 K개의 정수로 이산화하여 폭이 K인 히스토그램을 구성하고, 값이 이동함에 따라 히스토그램에 누적되어 최적의 의사 결정 트리 분할 지점을 위한 인덱스 역할을 한다. 깊이가 제한된 리프 중 가장 중요한 정보를 가진 리프에서 분할 우선 순위를 정한다. 해당 학습 방식은 동일한 층에서 정보 이득이 가장 높은 리프만 분할하기 때문에 효율적이며, 동시에 트리 깊이와 리프 수에 대한 제약 조건은 모델 복잡성을 줄여 과적합을 방지한다.

3.3 LSTM

Hochreiter와 Schmidhuber가 제시한 LSTM은 시계열 데이터 예측에 많이 사용되고 있다. 데이터 특성 중 장기적으로 형성된 주기를 가진 특성인 경우, 고전적인 RNN은 역전파하는 동안 기울기가 상당히 낮아지는 것으로 알려져 있다. 이러한 경사 소실 문제는 학습 성능을 크게 저하시키며, RNN의 장기 의존성 문제를 보완하기 위해 LSTM이 제안되었다. LSTM은 은닉층의 메모리 셀에 입력, 망각, 출력 게이트를 추가하여 중요한 정보만 기억한다.

[그림2. LSTM 모델 구조]

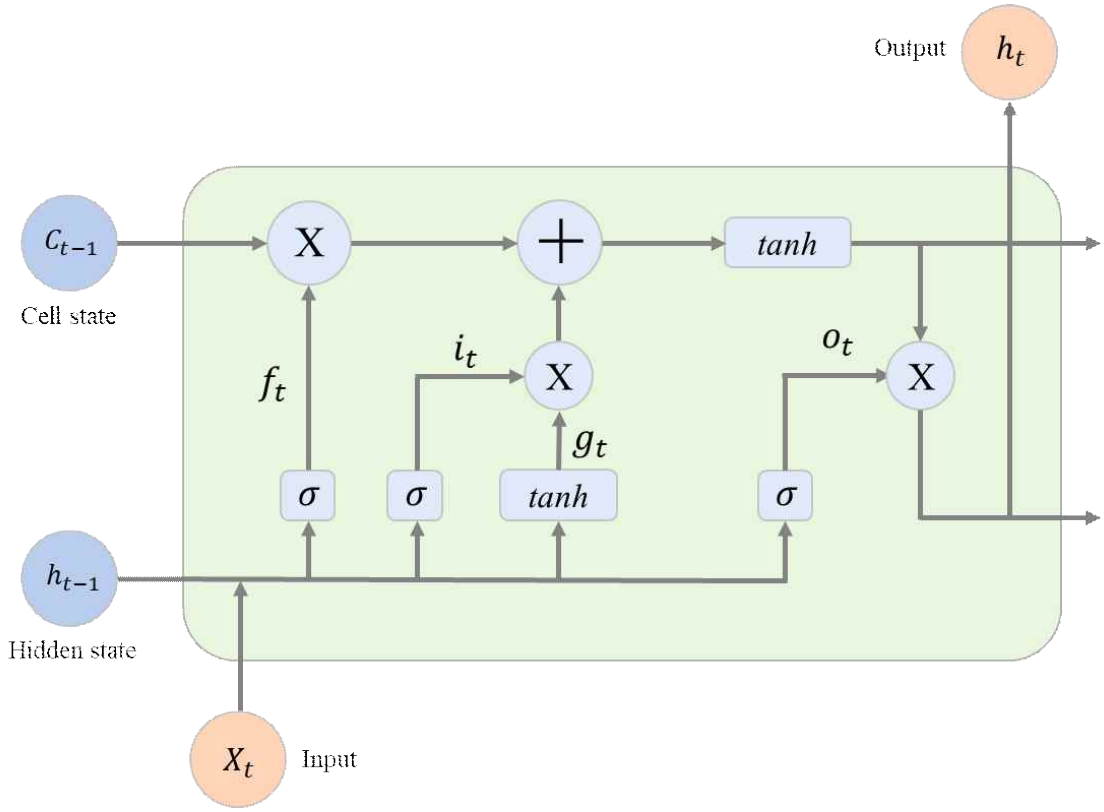

3.4 Stacked ensemble

스태킹 앙상블 모델은 개별 모델의 예측력을 보완하여 최종 모델의 예측력을 향상시킨다. 이 방법에는 여러 기본 모델의 예측을 최적으로 결합하도록 메타러너를 학습하는 것을 포함한다. 처음에는 서로 다른 모델을 개별적으로 학습시킨 다음 그 예측을 메타 학습자의 입력으로 사용한다. 2계층 스태킹에서 K-배 교차 검증을 통해 생성된 기본 모델의 예측은 새로운 특징 집합을 형성한다. 이 집합은 원래 레이블과 함께 선형 회귀와 같은 간단한 알고리즘을 사용하여 메타 학습자를 훈련시켜 최종 모델을 생성하는 데 사용된다. 스태킹의 강점은 각 기본 모델의 강점과 약점을 효과적으로 파악하여 성능과 일반화 능력을 크게 향상시키는 메타 학습기에 있다. 본 연구에서는 태양광 발전량 예측을 위한 기본 모델로 두 가지 머신러닝 알고리즘인 LightGBM과 XGBoost를 활용하여 일반적으로 적용 가능한 스택형 앙상블 알고리즘을 제안한다.

[그림3. Stacked ensemble 모델 구조]

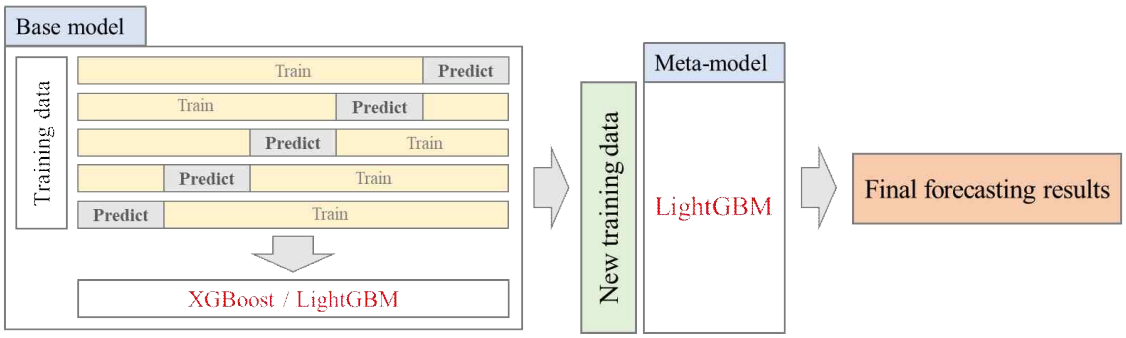

3.5 평가 지표

4가지 머신러닝 모델의 예측 성능을 평가하기 위해 일반적으로 사용되는 네 가지 오차 지표인 결정계수(R^2), 평균 제곱 오차(RMSE), 평균 절대 오차(MAE) 및 평균 제곱 오차(MSE)를 사용한다. 평균 절대 백분율 오차(MAPE)는 흔히 사용되는 성능 평가 지표이지만, 원래 값보다 높은 오차가 낮은 오차보다 더 큰 절대 백분율 오차를 발생시키는 비대칭성이 있기에 사용하지 않는다. 또한 MAE는 RMSE에 비해 전력 계산 방법에 더 높은 민감도를 보이는데, 이는 MSE가 조도 예측의 오차 상승에 더 민감하게 반응하고 전력 변환 방법의 영향을 덜 받기 때문일 수 있다.

Ⅳ. 분석 결과

4.1 데이터 셋

태양광 발전량을 예측하기 위해서는 먼저 분석 대상 태양광 발전소를 선정해야 한다. 본 연구에서는 대한민국 경상남도에 위치한 발전소의 데이터를 선택했다. 해당 지역에 위치한 모든 태양광 발전소의 시간당 평균 발전량 데이터는 한국전력거래소(KPX)에서, 기상 데이터는 국가기후데이터센터에서 수집했다. 기상 데이터는 경남에 위치한 개별 관측소의 시간별 기상 관측 데이터를 수집하여 동 시간대 모든 관측값의 평균값을 구해 이를 경남 지역 전체 시간별 평균 기상 데이터로 재구성하였다. 그림 4는 수집된 기상 변수(일사량, 기온, 강수량, 풍속, 풍향 등 총 11개) 간의 상관관계 히트맵을 보여준다. 0.6 이상의 높은 상관관계를 보이는 변수들이 있어 다중공선성 문제가 존재할 가능성이 크다는 것을 알 수 있다. 다중공선성은 회귀

분석에서 독립 변수 간의 상관관계가 높을 때 모델의 예측 성능을 떨어뜨리고 과적합을 유발할 수 있다. 또한 변수의 중요성을 왜곡할 수 있으므로 이를 해결하기 위해 본 연구에서는 Elastic net을 이용한 주요 변수 선택(차원 축소)를 수행한다. Elastic Net은 Ridge와 Lasso 회귀의 기능을 결합한 정규화 기법으로, 다중공선성이 우려되는 고차원 데이터 세트에 효과적이다. Elastic Net은 L1과 L2 페널티를 모두 통합하여 변수 선택과 정규화를 동시에 수행함으로써 이 문제를 해결한다. 이 방법은 특히 복잡한 데이터 세트를 다룰 때 모델 구축에 대한 유연하고 강력한 접근 방식을 제공한다.

[그림4. 기상변수 간 상관관계 히트맵]

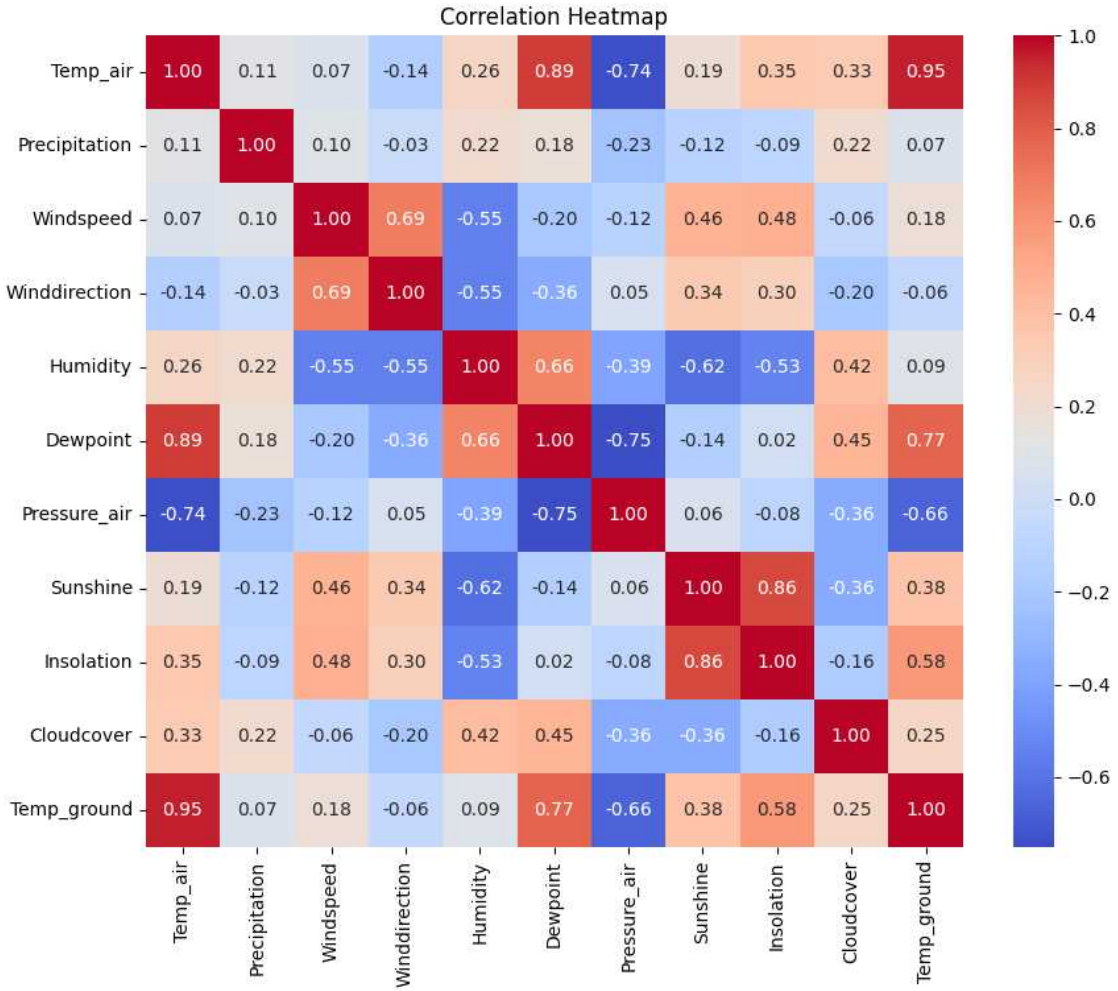

최종적으로 강수량과 이슬점이라는 두 가지 기상 변수는 α = 0.001 수준에서 제외했다. 본 연구에서는 2020년 1월 1일 00시부터 2023년 7월 31일 23시까지 3년 7개월간의 시간별 데이터를 모델 학습을 위한 훈련 데이터로 사용했으며, 각 모델의 성능을 평가하기 위한 테스

트 기간은 2023년 8월 1일 00시부터 2023년 8월 31일 23시까지로 설정한다.

위의 절차로 최종 수집된 데이터는 표1이다.

[표1. 최종 데이터]

구분	변수 특징	데이터(해상도: 1h)
입력	시간	년, 월, 일, 시
	기상 변수	온도, 풍속, 풍향, 습도, 기압, 일사량, 일조량, 전운량, 지면온도
	미세먼지	PM_{10}, $PM_{2.5}$
	온실가스	SO_2, NO_2, CO, O_3
출력	태양광 발전량 데이터	

미세먼지 및 온실가스 농도 데이터는 우리나라 환경청인 에어코리아의 전국 실시간 대기오염도 및 측정소 관측 자료를 통해 수집했다. 이 연구의 목적은 태양광 발전량 예측 모델을 구축할 때 미세먼지 및 온실가스의 영향을 분석하는 것이다. 따라서 변수의 유효성을 검증하기 위해 (1) 기상 변수, (2) 기상 변수와 미세먼지, (3) 기상 변수와 온실가스, (4) 전체(기상 및 온실가스, 미세먼지), 총 4가지 시나리오로 데이터 셋를 구성한다.

4.2. 태양광 발전량 예측 모델 성능 비교

본 연구에서는 태양광 발전량 예측을 위한 4가지의 데이터와 4개의 모델을 조합하여 총 16개의 예측 모델을 분석한다. 또한 그리드 탐색 방법과 베이지안 최적화를 사용하여 학습 데이터에 따라 모델의 파라미터를 최적화했다. 각 모델의 예측력을 비교하기 위해 본 연구에서는 각 모델의 성능 평가 요소를 계산했으며, 그 결과를 표2에 제시한다. 단일 모델 중에서는 LightGBM이 모든 데이터셋에서 가장 낮은 RMSE 값을 보였으며, '날씨+PM/GHG' 모델에서 11.2146으로 가장 우수한 성능을 보였다. 또한 LightGBM 대비 XGBoost 모델의 평균 RMSE 값 차이는 1.08로 유사한 성능을 보인다. LSTM은 최대 19.6150, MAE 14.8621로 가장 높은 오차를 보이지만 0.95 이상의 높은 R^2을 갖고 있기에 해당 모델 또한 데이터를 잘 설명하고 있다. 단일 모델 대비 스택 앙상블 모델은 모든 데이터 셋에서 일관되게 우수한 성능을 보이며, 단일 모델 대비 최대 15.52%의 RMSE 값의 향상이 나타난다. 이는 앙상블 모델이 단일 모델보다 복잡한 환경 변수의 영향을 더 잘 통합하여 예측 성능을 향상시킬 수 있음을 시사한다. '날씨 + PM/GHG' 스택 앙상블 모델은은 RMSE 10.7245, MAE 6.4501로 가장 낮은 오차를 보였으며, R^2 값은 0.9862로 나타나 모델의 안정성과 우수한 예측 정확도를 입증했다. 데이터 셋을 기준으로 모델을 비교를 해보면, ‘날씨’를 기준으로 '날씨 +

PM' 에서는 스택 앙상블, LightGBM이 성능 향상을 보였다. 하지만 최대 성능 향상 정도가 0,52%에 그치므로, PM 변수가 모델 성능에 상대적으로 더 긍정적인 영향을 미치지만 그 영향은 크지 않다. 반면, '날씨 + GHG'에서는 스택 앙상블과 XGBoost 모델이 성능 향상을 보이며, 이 역시 향상 정도는 미미하다. 따라서 미세먼지 및 온실가스 농도가 태양광 발전량에 유효한 영향을 미치지 않으며, 특정 모델은 환경 변수의 영향을 효과적으로 학습하여 예측 성능을 향상시킬 수 있는 반면, 다른 모델은 불필요한 정보로 인해 성능이 저하될 수 있다.

[표2. 모델 성능 평과 결과]

Dataset			RMSE	MAE	MSE	R^2
1	Weather	Stacked ensemble	11.0401	6.6573	121.88	0.9854
		LightGBM	11.5406	6.8913	133.1844	0.9840
		XGBoost	11.7203	7.1504	137.3665	0.9835
		LSTM	17.3475	12.4682	300.9371	0.9639
2	Weather + PM	Stacked ensemble	10.9826	6.5692	120.6165	0.9855
		LightGBM	11.4977	6.9889	132.1973	0.9841
		XGBoost	13.0001	7.7861	169.0039	0.9797
		LSTM	18.6931	13.5628	349.4316	0.9581
3	Weather + GHG	Stacked ensemble	11.0030	6.6166	121.0668	0.9855
		LightGBM	11.7156	7.0447	137.2564	0.9835
		XGBoost	12.6112	7.5726	159.0428	0.9809
		LSTM	16.8774	12.1153	284.8481	0.9658
4	Weather + PM/GHG	Stacked ensemble	10.7245	6.4501	115.0156	0.9862
		LightGBM	11.2146	6.9358	125.7684	0.9849
		XGBoost	12.8100	7.5284	164.0954	0.98031
		LSTM	19.6150	14.8621	384.7480	0.9538

4.3. Stacked ensemble 모델 세부 구조 및 성능 비교

본 연구의 주요 목적 중 하나는 서로 다른 데이터셋을 기반으로 한 스택 앙상블 모델의 세부 구조와 예측 성능을 분석하여 최적의 모델을 찾는 것이다. 앙상블 모델은 여러 베이스 모델의 예측 결과를 조합하여 최종 예측을 도출하는 모델로, 본 연구에서는 LightGBM과 XGBoost를 베이스 모델로, LightGBM을 메타 모델로 사용한다. 스택 앙상블 모델에서 각 변수별 최적 모델의 세부 구조는 표3과 같다.

또한, 스택 앙상블 모델의 변수 조합별 태양광 발전량 예측 모델의 평가 데이터에 대한 실제값과 예측값은 그림5에 나타냈다. 가로축은 테스트 데이터의 시간 지수를, 세로축은 태양광 발전량을 나타낸다. 여기서 파란색 선은 실제값, 주황색 선은 예측값이며, 같은 세로축에서 파란색과 주황색 선 사이의 간격은 태양광 발전량의 오차이다.

[표3. Stacked ensemble 모델 세부 구조]

Dataset	Base model			RMSE	MAE
	LightGBM	XGBoost	Total		
Weather	5 (83.81%)	4 (16.19%)	9	11.0401	6.6573
Weather + PM	5 (75.93%)	6 (24.07%)	11	10.9826	6.5692
Weather + GHG	6 (86.90%)	5 (13.10%)	11	11.0030	6.6166
Weather + PM/GHG	5 (88.40%)	2 (11.60%)	7	10.7245	6.4501

[그림5. Stacked ensemble의 태양광 발전량 예측 그래프]

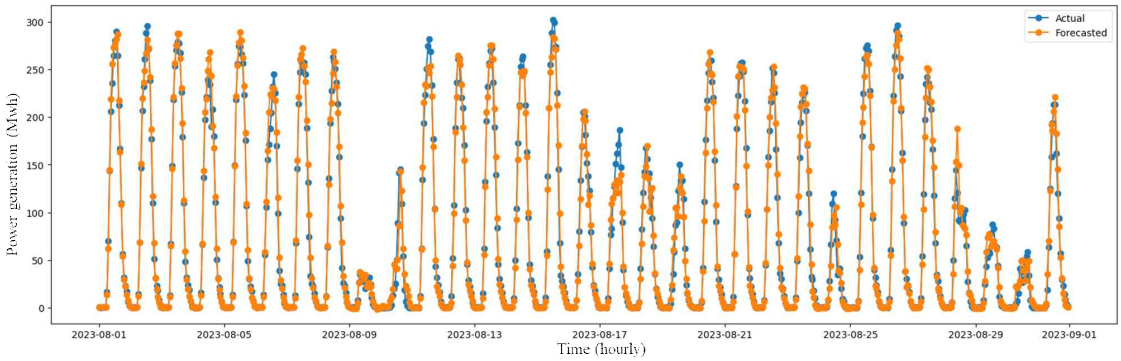

(a) 데이터셋1: Weather

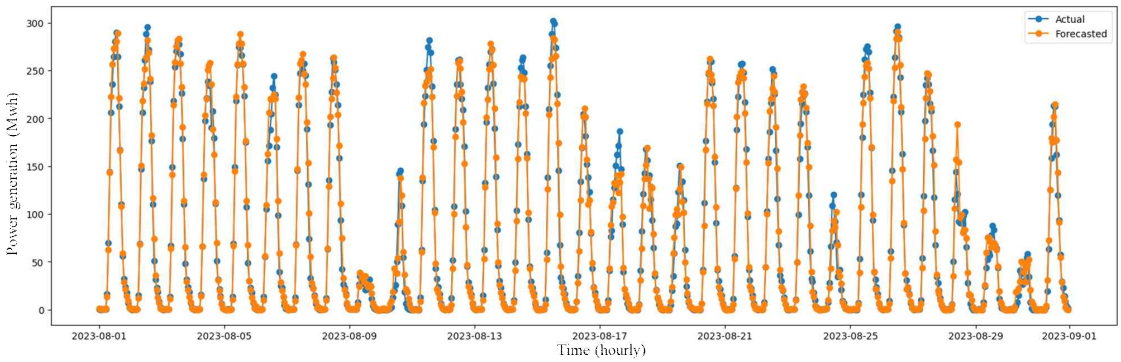

(b) 데이터셋2: Weather + PM

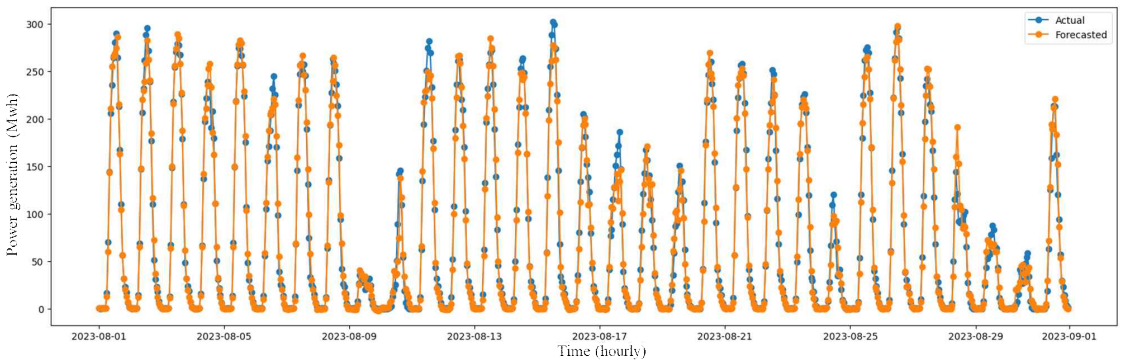

(c) 데이터셋3: Weather + GHG

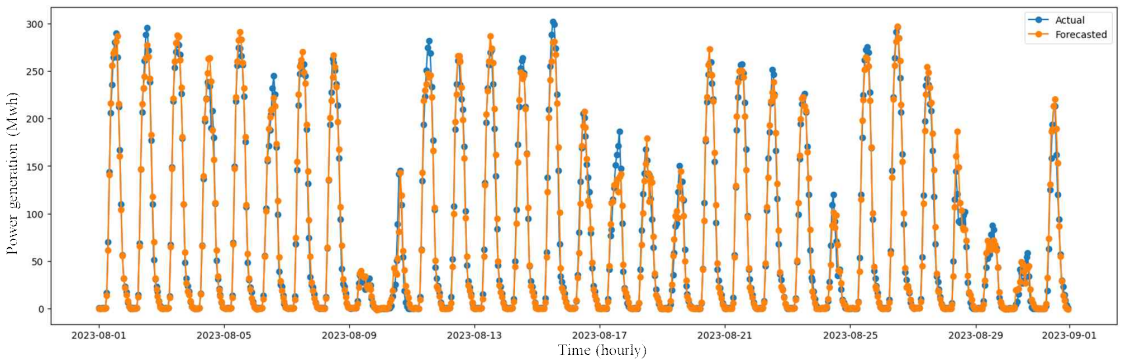

(d) 데이터셋4: Weather + PM/GHG

'날씨' 대비 '날씨 + PM'에서 LightGBM의 기여도가 75.93%로 약간 감소한 반면, XGBoost의 기여도는 24.07%로 증가했다. 이는 미세먼지 변수가 XGBoost 모델이 더 적합하다는 것을 보여준다. 10.9826의 RMSE와 6.5692의 MAE를 기록하여 날씨 변수만 사용한 모델에 비해 전반적인 모델 성능이 개선됐다. 반대로 '날씨 + 온실가스' 데이터 세트에서는 LightGBM의 비중이 86.90%로 증가하여 온실가스 변수가 LightGBM의 예측 능력을 향상시킨 것으로 나타났다. 포괄적인 '날씨 + PM/GHG' 데이터셋을 사용할 경우, LightGBM 점유율은 88.40%로 네 가지 스택형 앙상블 모델 중 가장 높은 LightGBM 기여도를 가진다. 가장 뛰어난 성능을 보여주는 '날씨 + PM/GHG' 스택 앙상블 모델은 10.7245로 가장 낮은 RMSE와 6.4501의 MAE를 기록한다. LightGBM의 가중치가 가장 큰 스택 앙상블 모델이 가장 우수한 성능을 보였다는 사실은 LightGBM이 다변량 데이터의 복잡한 상호작용을 정확하게 포착하고 있다는 것이다. LightGBM은 의사 결정 트리 기반 모델이며 속성 중요도 및 데이터 분할의 유연성이 높기 때문에, RMSE 및 MAE 지표의 개선에서 알 수 있듯이 복잡한 상호작용과 비선형 패턴이 있는 환경 데이터를 더 정확하게 예측할 수 있다. XGBoost는 LightGBM에서 발생할 수 있는 과적합을 방지하고 다양성을 추가하여 전체 모델의 일반화 능력을 향상시킨다. 따라서 이 연구는 LightGBM과 XGBoost로 구성된 스택형 앙상블 모델이 다양한 환경 변수를 포함하여 복잡성이 증가한 다변량 데이터 세트에서 강력한 예측 성능을 제공한다는 것을 확인했다.

4.4. 토론

2023년 8월 13일, 기상청은 폭염 일수가 11.7일이라고 발표하며. 이는 연평균 폭염 일수(11.0일)를 넘어선 수치이다 (그림 6). 이처럼 한국의 여름철은 태풍과 폭염이 연달아 발생하는 것이 특징이며, 피크 시간대 및 전력 수요 급증 시 안정적인 전력 공급을 위해서는 선제적인 이상기후 예측이 중요하다. 극심한 폭염으로 인한 정전의 예로는 2020년 캘리포니아 정전 사태가 있다. 2020년 8월, 미국 캘리포니아주는 섭씨 38도가 넘는 고온으로 인해 냉방 수요가 급증하며, 전력 시스템에 과부하가 걸렸고 대규모 정전을 방지하기 위해 순환 정전이 시행되었다. 순환 정전은 전력 사용량이 가장 많은 시간대에 순차적으로 전력을 차단하여 전력 수요 급증을 완화하기 위해 캘리포니아 독립계통운영사업자(CAISO)가 의무화한 짧은 시간 동안의 통제된 정전이다. 태양광 발전은 일몰 후 효율이 급격히 감소하고 열대야 현상으로 인해 19시 이후 냉방 전력 수요가 급증하는 데 특히 취약하다.

[그림6. 경남 일평균 태양광 발전량 및 최고 기온 추이 (23.08)]

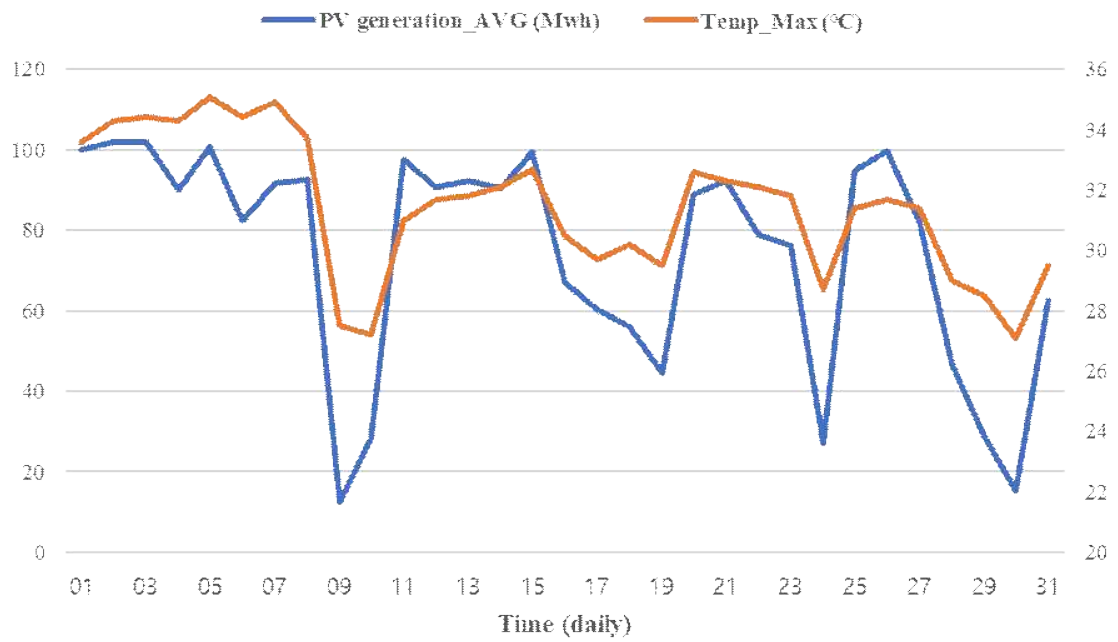

결과적으로 캘리포니아의 전력 부족은 폭염으로 인한 전력 수요 급증에 대한 예측 실패와 급진적인 에너지 전환 정책으로 인한 예비 전력 부족으로 인해 발생했다. 따라서 전력 피크에 대응하기 위해 태양광 발전량 예측의 정확도를 높이는 것과 함께 선제적인 이상기후 예측이 중요하다. 폭염 시 일사량 증가에 비례하여 태양광 발전량이 증가하도록 발전 믹스를 조정하여 태양광 발전 비중을 높이는 방안을 고려할 수 있다.

또한 최적 효율 온도가 섭씨 25인 태양광 발전기의 폭염시 발전 효율 저하 우려와 달리, 폭염(낮 최고기온이 섭씨 33도 이상)에도 태양광은 충분한 전력을 생산할 수 있다. 예를 들어, 2023년 8월 한국에서 폭염이 지속되는 동안 태양광 발전은 국가 전력 수요의 20.0%를 충족했다. 8월 3일, 한국은 폭염으로 인해 전력 수요가 급증했으며 일부 지역은 일몰 후 섭씨 30도가 넘는 초열대야가 나타났다. 0시부터 13시까지 태양광 발전량은 17,843MW로 전체 실제 수요(89,213MW)의 20%를 차지했다[전력거래소 실시간 태양광 추정 통계]. 여름철 피크시간대 태양광 발전량이 증가했다는 것은 온실가스를 배출하는 LNG 대신 태양광으로 피크시간대 전력을 추가로 공급할 수 있다는 것을 의미한다. 또한 2016년까지 한국의 여름철 전력 소비 피크 시간은 14~15시였지만, 2021년 이후 16~17시으로 변화했다 (그림 7).

[그림7. 시간당 실제 전력 수요 및 시장 수요]

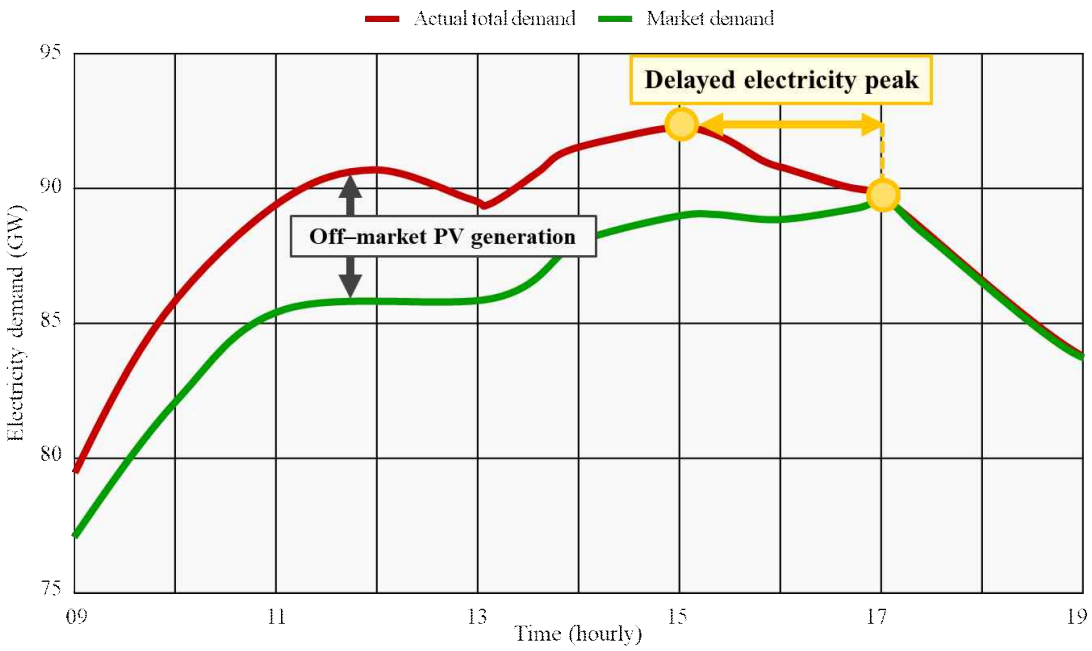

2021년 7월 기준 한국의 총 태양광 발전 용량은 약 20.3GW로, 전력 시장에서 거래되는 태양광 발전(5.1GW), 한전과의 전력 구매 계약(PPA)을 통해 발전한 태양광 발전(11.5GW), 가정용 태양광 발전(3.7GW)으로 구성된다. 이 중 5.1GW(약 25%)는 실시간 계량이 가능한 전력 시장에 등록되어 있고, 나머지 75%는 계량되지 않은 상태로 수요 예측에만 반영된다. 따라서 피크 수요가 늦은 오후로 이동하는 것은 계량되지 않은 태양광이 한낮 수요를 충당하기 때문이며, 태양광이 수요 감축과 공급 능력에 크게 기여하고 있다.

Ⅴ. 결론 및 한계

5.1. 결론 및 시사점

본 연구에서는 기상변수, 미세먼지, 온실가스 농도의 영향을 함께 고려하여 머신러닝 기반의 태양광 발전량 예측 모델을 구축했다. Light GBM-XGBoost 앙상블 모델을 기반으로 한 결과, RMSE 값과 MSE값이 각각 최대 2.85%, 3.11%까지 감소했으며, 네 가지 변수의 조합을 고려하는 것이 예측 성능 향상에 도움이 된다. 그러나 일부 단일 모델은 이와 반대의 결과를 보이고, 예측 성능 차이가 미미하므로 기상 변수만을 고려하여 태양광 발전량을 예측하는 것이 합리적이다. 이 연구의 의의는 기상 데이터를 활용한 머신러닝 기반 태양광 발전량 예측 모델에서 미세먼지와 온실가스 농도를 함께 고려했다는 것이다. 또한, 본 연구에서는 최적의 발전량 예측 모델을 얻기 위해 기상변수의 조합을 검토했으며, 기상변수 중 강수량과 이슬점 정보가 예측 성능을 저하시키는 요인으로 나타났다. 이러한 결과는 향후 다른 태양광 발전량 예측 알고리즘 개발 및 적용에 유용하게 활용될 수 있을 것으로 기대된다. 본 연구에서 도출된 결론을 바탕으로 태양광 발전량 사전 예측 모델을 구축하면 태양광 발전량 예측의 정확도를 향상시켜 국내 전력계통 안정화에 어느 정도 기여할 것으로 기대한다.

5.2. 한계

그러나 본 연구는 태양광 발전량 예측 모델을 구축하는 과정에서 몇 가지 한계점이 있다. 첫째, 본 연구는 사계절이 뚜렷한 우리나라를 기준으로 했다는 것이다. 그러나 우리나라는 사계절이 뚜렷하고 여름과 겨울에 따라 태양광 발전량이 크게 달라지며, 변수의 중요도가 동적으로 변화한다. 따라서 본 연구에서는 모든 변수를 고려한 앙상블 모델이 다른 단일 모델보다 우수한 성능을 보이지만, 1년 동안의 기온이나 날씨 변화가 상대적으로 작은 국가에서는 이 모델이 가장 우수한 예측력을 갖는다는 것이 입증되지 않았다. 따라서 본 연구 결과를 모든 국가에 적용하는 것은 부적절하며, 각 국가의 데이터를 활용한 추가적인 비교 분석이 필요하다. 둘째, 본 연구에서는 미세먼지 및 대기 중 온실가스 농도가 태양광 발전량에 미치는 영향을 파악하기 위해 이들 변수의 상관관계 및 다중공선성을 고려하지 않았다. 그러나 PM_{10}과 $PM_{2.5}$ 사이의 높은 상관관계, $PM_{2.5}$와 O_3 사이의 유의미한 상관관계를 보여주는 연구들이 있다. 따라서 최적의 태양광 발전량 예측 모델을 구축하기 위해서는 추가적인 변수 선정 과정이 필요하다.