데이터마이닝 팀플 개선안

개선안 1

- 지하철 역 막차 시간대별(ex. 30분씩 분류) 변수 추가

+

- 심야 버스 노선 행정동별 겹치는 부분을 분류하여 변수 추가

서울시, 추석 연휴 대중교통 막차 새벽 2시로 연장

홍주연 기자 | 입력 : 2022.09.05 19:32:51

(매경DB)

연말 대중교통 막차시간 연장...24시간 체제 가동

김승환 | tbs3@naver.com | 2018-12-11 08:54

[앵커]
서울시가 연말 대중교통 막차 시간을 새벽 한 시까지 연장하기로 했습니다.

모임이 잦은 만큼, 심야 교통대란과 음주운전을 막겠다는 취지인데요.

자정부턴 심야 버스도 운행하는 걸 생각하면 사실상 24시간 버스를 이용할 수 있게 되는 겁니다.

다음 주 월요일부터 적용됩니다.

개선안 2

날씨 데이터 추가
온도에 따른 유동인구 분석을 통해 데이터 추가

사회

계속되는 한파에... 음주운전 얼어붙었나

김헌주 기자
입력 2018-02-06 22:46 | 수정 2018-02-07 00:42

2개월 간 전국 음주운전 단속... 작년보다 적발 건수 10% 줄어

올겨울 맹추위가 음주운전마저 얼어붙게 한 것으로 나타났다. 혹한의 날씨가 연일 계속되면서 직장인들 사이에 질펀하게 술을 마시는 회식의 빈도가 크게 줄어든 탓으로 여겨진다.

개선안 3

- 기존 수상작에서는 예측모델을 만들 때 상위 요인 4개를 정함
경로분석을 이용하여 중요도 설정 후 예측모델 만들기
표준화 회귀계수를 중요도로 받아들여도 된다.

2) 랜덤포레스트 결과

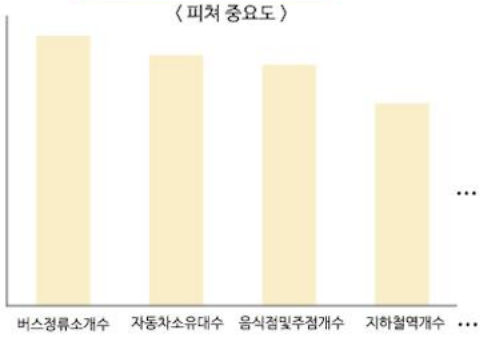

Feature	VIF
CCTV 개수	7.915338
가로등 개수	4.489660
버스 정류장 수	20.798093
음식점 개수	123.626902
주점 개수	74.321359
주차장 개수	19.524269
지하철역 수	11.811429
자동차 소유 대수	25.111234

(1) 음식점 수와 주점 수의 VIF 값이 123, 74로 유독 높게 나타나, 다중공선성 문제를 해결하기 위해 하나로 통합.

(2) 랜덤포레스트의 피쳐 중요도를 확인, 음주운전에 영향을 주는 상위 4개의 요인인, 버스 정류소 개수, 음식점 및 주점 개수, 지하철역 개수, 자동차 소유 대수를 예측모델에 학습할 요인으로 결정.

원인변수

버스 정류장 수

지하철 막차 시간

매개변수

주점 갯수

종속변수

음주운전 발생

장점)
1. 여러 인과관계를 알 수 있다
2. 원인변수>매개변수>종속변수로 이르는 간접적인 영향을 고려할 수 있다
3. 표준화 회귀계수로 중요도 설정 가능

단점)
1. 모델이 복잡하다
2. 인과관계가 가설을 바탕으로 세워짐

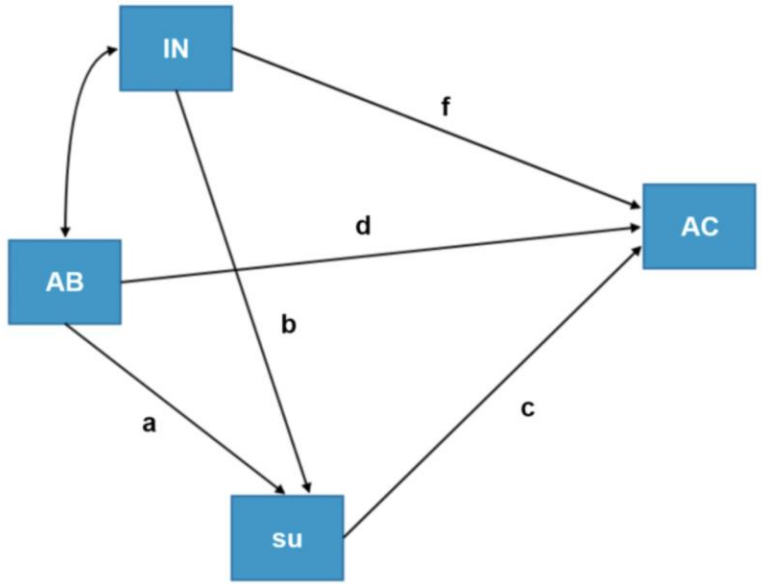

Path Modeling

모델의 변

수

* AC: 개인이 성공 성취도, * IN: 가계의 수입, * AB: 개인의 능력, * SU: 개인의성공열정

2. lavaan을 분석한 구조방정식이 경로분석 결과

일반적으로 lavaan에서는 공분산의 입력이 참 편리하다. raw데이터가 아니여도 공분산으로 입력이 된다는 것도 생각해보면 편리하다는 생각이 든다.

Copy

```
ibrary(lavaan)
#01 데이터 입력 ####
covMat =lav_matrix_lower2full(c(26.5,
                                21.5,37.9,
                                23.5,25.2,41.7,
                                16.5,14.6,14.5,16.8))
colnames(covMat) <- rownames(covMat) <-c("AC", "IN", "AB","SU")
#AC:개인이 성공 성취도, IN:가계의 수입, AB:개인의 능력, SU:개인의성공열정
covMat  #공분산 행렬로 결과 확인

#02 모델구성 -  Path model 구성####
 ## Direct effect, indirect effect는 paste()를 이용하여 추가한다.
PathModel <- '
SU ~ a*AB +b*IN
AC ~ c*SU + d*AB +f*IN
AB ~~ IN
'
#03 분석진행은 sem을 이용하여 한다. ####
# sem(모델, sample.cov= 공분산 행렬, sample.nobs=샘플의 개수)
fitM <- sem(PathModel, sample.cov = covMat, sample.nobs = 300,
            fixed.x = FALSE)
#04 결과보기 ####
summary(fitM, standardized=TRUE,fit.measures=TRUE, rsquare=T)
```

측정지표 체크

```
summary(fitM, standardized=TRUE,fit.measures=TRUE, rsquare=T)
lavaan 0.6-6 ended normally after 35 iterations

  Estimator                                         ML
  Optimization method                           NLMINB
  Number of free parameters                         10

  Number of observations                           300

Model Test User Model:

  Test statistic                                 0.000
  Degrees of freedom                                 0

Model Test Baseline Model:

  Test statistic                               708.063
  Degrees of freedom                                 6
  P-value                                        0.000

User Model versus Baseline Model:

  Comparative Fit Index (CFI)                    1.000
  Tucker-Lewis Index (TLI)                       1.000

Loglikelihood and Information Criteria:

  Loglikelihood user model (H0)              -3366.288
  Loglikelihood unrestricted model (H1)      -3366.288

  Akaike (AIC)                                6752.576
  Bayesian (BIC)                              6789.614
  Sample-size adjusted Bayesian (BIC)         6757.899
```

```
Root Mean Square Error of Approximation:

  RMSEA                                          0.000
  90 Percent confidence interval - lower         0.000
  90 Percent confidence interval - upper         0.000
  P-value RMSEA <= 0.05                             NA

Standardized Root Mean Square Residual:

  SRMR                                           0.000

Parameter Estimates:

  Standard errors                             Standard
  Information                                 Expected
  Information saturated (h1) model          Structured

Regressions:
                   Estimate  Std.Err  z-value  P(>|z|)   Std.lv  Std.all
  SU ~
    AB         (a)    0.192    0.037    5.190    0.000    0.192    0.303
    IN         (b)    0.257    0.039    6.631    0.000    0.257    0.387
  AC ~
    SU         (c)    0.629    0.047   13.327    0.000    0.629    0.501
    AB         (d)    0.248    0.032    7.857    0.000    0.248    0.311
    IN         (f)    0.160    0.034    4.708    0.000    0.160    0.191

Covariances:
                   Estimate  Std.Err  z-value  P(>|z|)   Std.lv  Std.all
  AB ~~
    IN               25.116    2.708    9.273    0.000   25.116    0.634

Variances:
                   Estimate  Std.Err  z-value  P(>|z|)   Std.lv  Std.all
   .SU               10.221    0.835   12.247    0.000   10.221    0.610
   .AC                6.828    0.558   12.247    0.000    6.828    0.259
    AB               41.561    3.393   12.247    0.000   41.561    1.000
```

Regression & covariance coef.
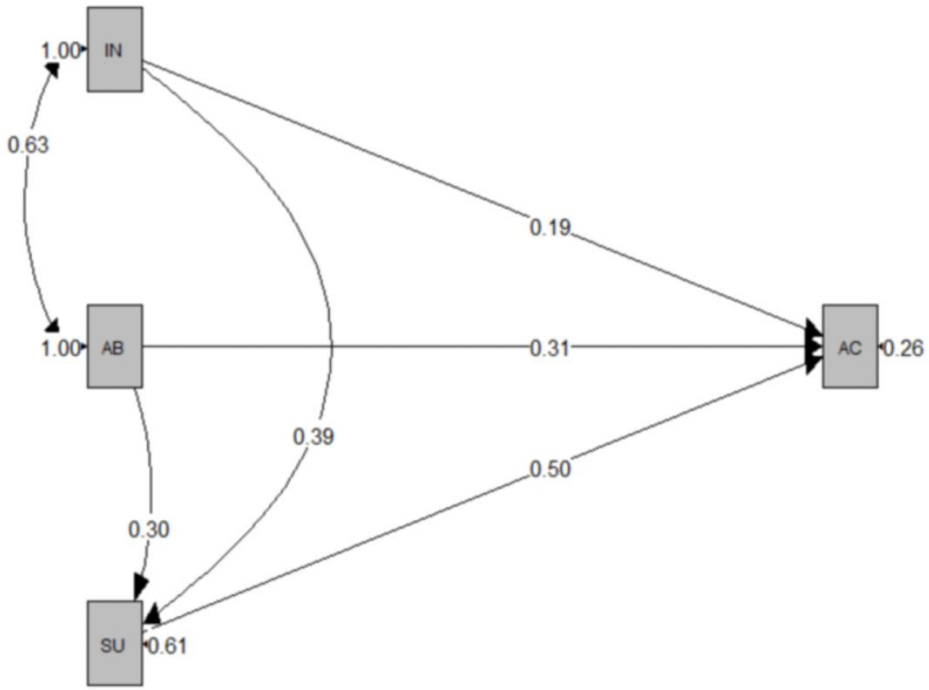
Dependent	Path	Independent	Coefficient	c.r	Sig.	p-value
SU	< --	AB	0.303	5.316	* * *	*0.000*
SU	< --	*IN*	*0.387*	*6.919*	* * *	0
AC	< --	SU	0.501	13.865	* * *	*0*
AC	< --	*AB*	*0.311*	*7.871*	* * *	0
AC	< --	IN	0.191	4.704	* * *	*0.000*
AB	< -- >	*IN*	*0.634*	*18.354*	* * *	0
SU	< -- >	SU	0.610	13.875	* * *	*0*
AC	< -- >	*AC*	*0.259*	*10.057*	* * *	0
AB	< -- >	AB	1			
IN	**< -- >**	**IN**	**1**